Arbre de décision

Ludovic Huang, Augustin Grudet

Sommaire

1. Histoire des arbres de décisions

2. Construction d'arbre
2.1 Principe de construction
2.2 Iterative Dichotomiser 3 (ID3)
2.3 Classification and Regression Trees (CART)

3. Élagage d'arbre

4. Limites et conclusion

Contexte et objectif

- Problème : prédire une décision à partir d'observations.
- Idée : une suite de tests simples et interprétables.
- Avantages : explicable, rapide à entraîner, baseline solide.
- Objectif : comprendre ID3 et CART, critères de split, élagage.

Exemple introductif, Ross Quinlan 1989

But : construire un arbre de décision général en nous basant sur les observations ci-contre afin de savoir si on peut jouer au tennis.

Outlook	**Temperature**	**Humidity**	**Windy**	**Play**
Sunny	Hot	High	False	No
Sunny	Hot	High	True	No
Overcast	Hot	High	False	Yes
Rainy	Mild	High	False	Yes
Rainy	Cool	Normal	False	Yes
Rainy	Cool	Normal	True	No
Overcast	Cool	Normal	True	Yes
Sunny	Mild	High	False	No
Sunny	Cool	Normal	False	Yes
Rainy	Mild	Normal	False	Yes
Sunny	Mild	Normal	True	Yes
Overcast	Mild	Normal	True	Yes
Overcast	Hot	Normal	False	Yes
Rainy	Mild	High	True	No

Table 1: Dataset introductif de Ross Quinlan (1989)

Sommaire

1. Histoire des arbres de décisions

2. Construction d'arbre
2.1 Principe de construction
2.2 Iterative Dichotomiser 3 (ID3)
2.3 Classification and Regression Trees (CART)

3. Élagage d'arbre

4. Limites et conclusion

Principe de construction

- À chaque nœud, choisir un attribut pour séparer les classes.
- Le choix maximise un critère de pureté (entropie, Gini).
- Répéter jusqu'à un critère d'arrêt.

Critères de pureté

- Entropie : $H(S) = -\sum_i p_i \log_2(p_i)$
- Gain d'information : $IG(S, A) = H(S) - \sum_v \frac{|S_v|}{|S|} H(S_v)$
- Gini : $G(S) = 1 - \sum_i p_i^2$

Attributs continus

- Pour un attribut numérique, tester des seuils t.
- On cherche le split binaire qui minimise Gini ou maximise le gain.
- CART gère nativement le numérique, ID3 nécessite une adaptation.

ID3 vs CART : Synthèse

Caractéristique	**ID3**	**CART**
Critère	Entropie	Gini
Type d'arbre	Multi-branches	Binaire uniquement
Tâches	Classification	Classif. & Régression
Élagage	Non	Oui (Pruning)

Sommaire

1. Histoire des arbres de décisions

2. Construction d'arbre
2.1 Principe de construction
2.2 Iterative Dichotomiser 3 (ID3)
2.3 Classification and Regression Trees (CART)

3. Élagage d'arbre

4. Limites et conclusion

Iterative Dichotomiser 3 (ID3)

Algorithm 1 Algorithme ID3

```
procedure ID3(S, Attributes)
    Créer un nœud Racine
    if tous les exemples de S sont de la même classe C then
        return Racine étiqueté avec la classe C
    end if
    if Attributes est vide then
        return Racine étiqueté avec la classe majoritaire de S
    end if
    Sélection de l'attribut :
    A ← l'attribut qui maximise le Gain d'Information
    Étiqueter Racine par A
    for chaque valeur possible v de A do
        S_v ← {x ∈ S | x_A = v}
        if S_v est vide then
            Ajouter une feuille avec la classe majoritaire de S
        else
            Ajouter le sous-arbre ID3(S_v, Attributes \ {A})
        end if
    end for
    return Racine
end procedure
```

ID3 sur l'exemple météo (Quinlan 1989)

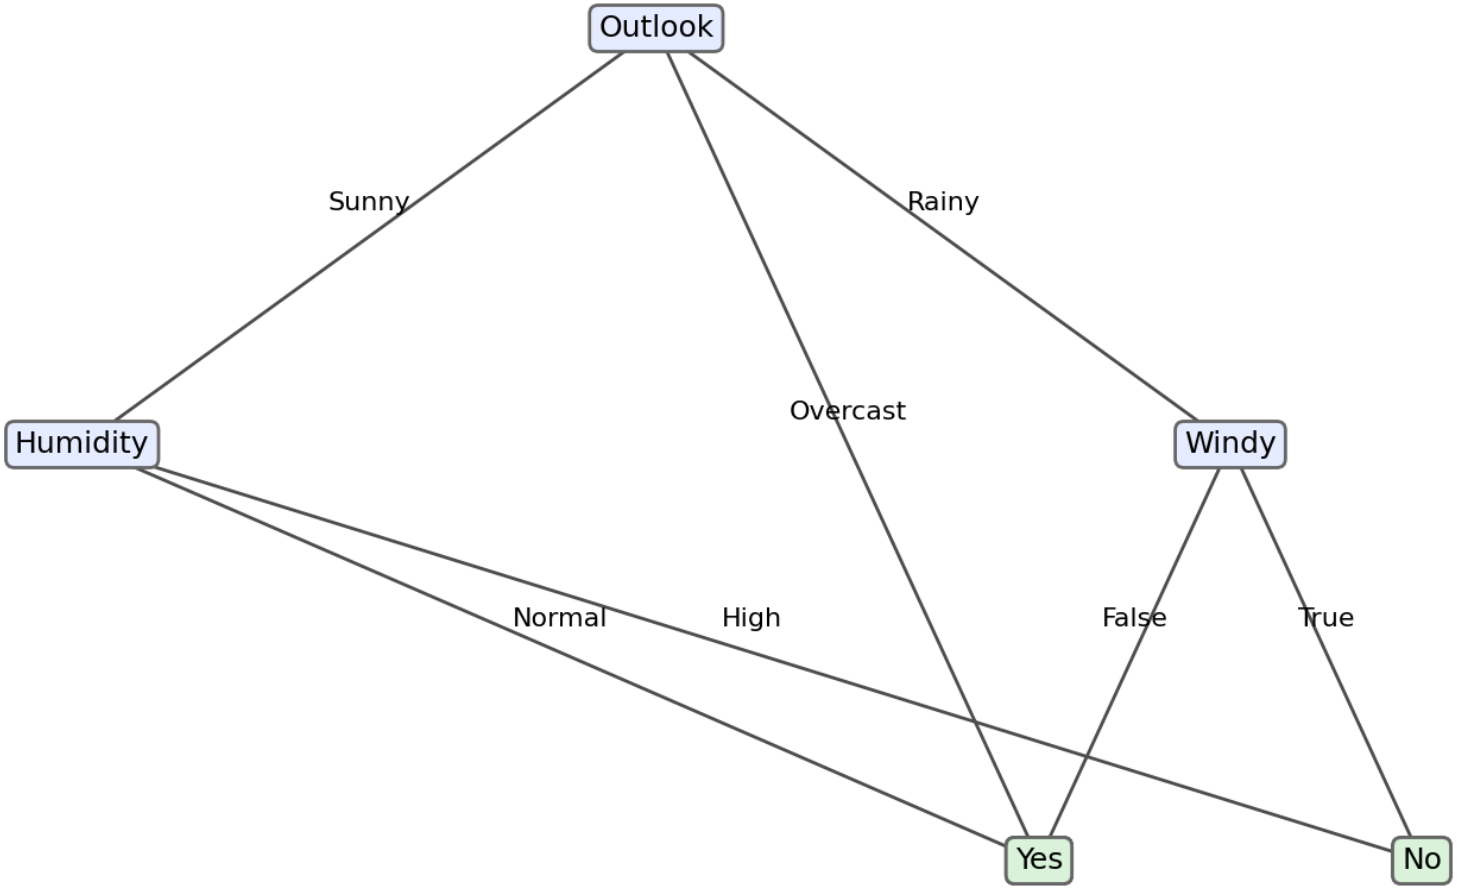

Figure 2.2.1: Arbre ID3 appris sur le dataset météo.

ID3 sur Drug200 (variables catégorielles)

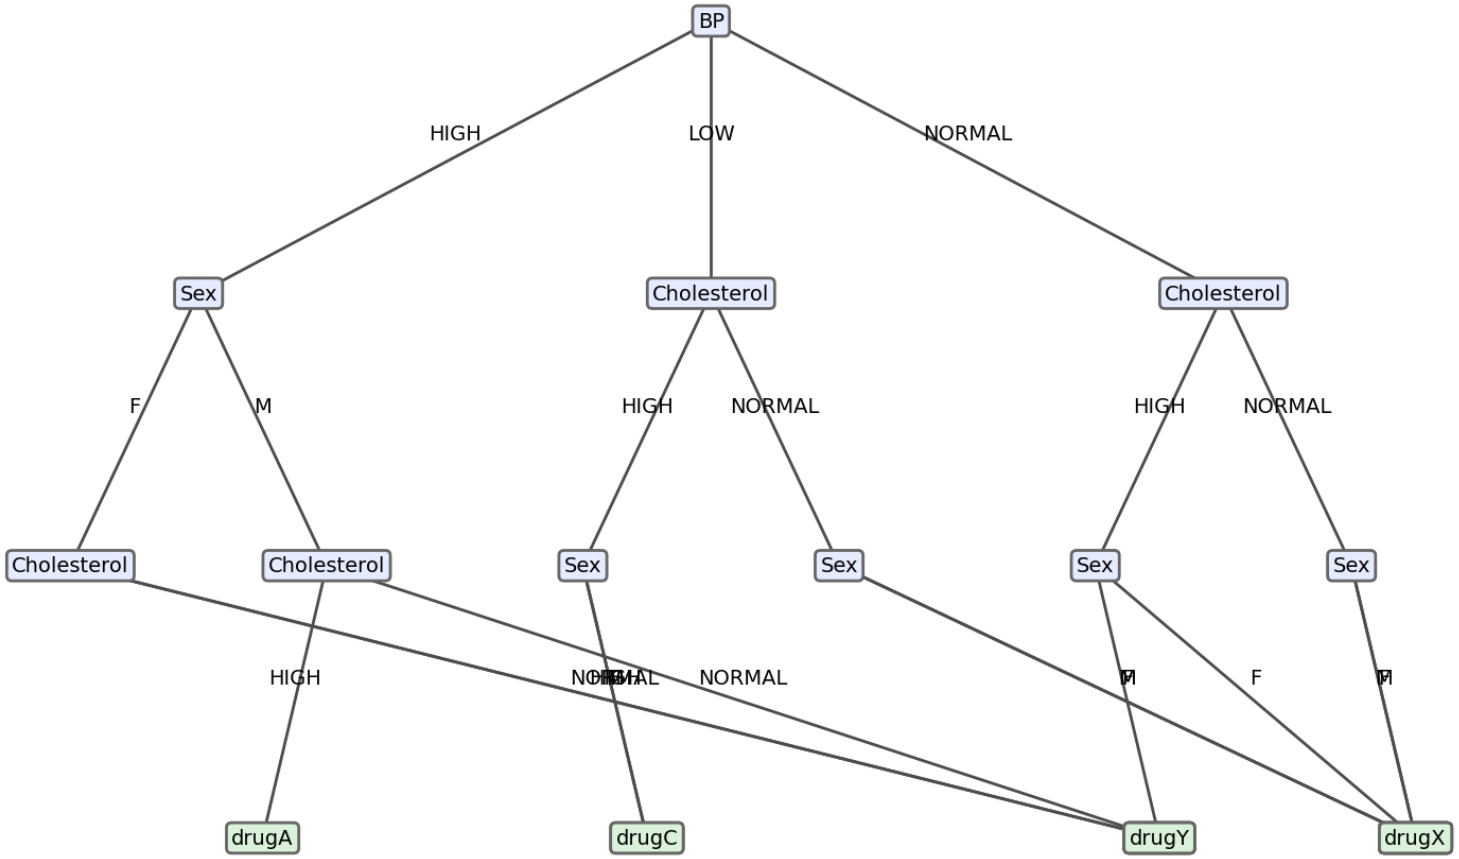

Figure 2.2.2: Arbre ID3 après suppression des variables continues (Age, Na_to_K).

Sommaire

1. Histoire des arbres de décisions

2. Construction d'arbre
2.1 Principe de construction
2.2 Iterative Dichotomiser 3 (ID3)
2.3 Classification and Regression Trees (CART)

3. Élagage d'arbre

4. Limites et conclusion

Classification and Regression Trees (CART)

Algorithm 2 Algorithme CART

```
procedure CART(D)
    if critère d'arrêt atteint (pureté, profondeur max, etc.) then
        return nœud feuille avec la classe majoritaire
    end if
    Recherche de la séparation optimale :
    (j, t) ← Trouver l'attribut j et le seuil t minimisant l'indice de Gini
    Division binaire :
    D_gauche ← {x ∈ D | x_j ≤ t}
    D_droite ← {x ∈ D | x_j > t}
    Créer un nœud Racine divisé par le test (x_j ≤ t)
    Racine.gauche ← CART(D_gauche)
    Racine.droite ← CART(D_droite)
    return Racine
end procedure
```

Pourquoi élaguer ?

- Un arbre profond sur-apprend facilement.
- L'élagage réduit la variance et améliore la généralisation.
- Compromis : complexité vs performance.

Post-pruning (CART)

- Construire l'arbre complet.
- Remplacer des sous-arbres par des feuilles si le score ne baisse pas.
- Coût-complexité : $R_\alpha(T) = R(T) + \alpha|T|$.

Limites

- Sensible au bruit et aux petites variations des données.
- Biais vers des attributs à nombreuses valeurs (ID3).
- Solutions : élagage, critères pénalisés, ensembles (Random Forest).

Conclusion

- Les arbres : interprétables et efficaces.
- ID3 : simple, entropie, multi-branches.
- CART : binaire, Gini, gère les variables continues + pruning.
- Perspectives : ensembles pour améliorer la robustesse.